Projeto de Inteligência Artificial

Diagnóstico de Câncer de Mama — 3ª Entrega Parcial

Dupla: Ailton Rodrigo da Silva Filho
Arthur Henrique da Silva Gomes

Professora: Patricia Bellin Ribeiro

Tema: Classificação de Tumores de Mama em Benignos ou Malignos utilizando Machine Learning.

1. Estrutura anterior consolidada

1.1 Introdução e Contextualização

O câncer de mama é uma das doenças de maior impacto na saúde global, sendo a principal causa de morte por câncer entre as mulheres em diversos países. A complexidade desta patologia exige métodos de diagnóstico que sejam não apenas rápidos, mas extremamente precisos, uma vez que a detecção precoce eleva drasticamente as chances de cura e permite tratamentos menos invasivos.

Este projeto fundamenta-se na utilização do conjunto de dados 'Breast Cancer Wisconsin (Diagnostic)', um recurso amplamente reconhecido na comunidade científica e de Machine Learning (WOLBERG; STREET; MANGASARIAN, 1995). O dataset contém informações extraídas de imagens digitalizadas de biópsias realizadas por aspiração por agulha fina (PAAF). Os dados quantificam características dos núcleos celulares, como o raio médio, a textura, a suavidade e a concavidade, permitindo que algoritmos de Inteligência Artificial aprendam a distinguir padrões associados a tumores benignos e malignos.

1.2 Relevância

A relevância deste projeto está ancorada na interseção entre tecnologia e medicina. O diagnóstico patológico tradicional, embora altamente confiável, está sujeito a variações interpretativas e à alta carga de trabalho dos profissionais. A implementação de modelos de IA como ferramenta auxiliar oferece:

- **Consistência Diagnóstica:** redução da subjetividade na análise morfológica celular.
- **Eficiência Operacional:** processamento rápido de dados para suporte imediato ao médico.
- **Redução de Erros:** auxílio na minimização de falso-negativos, garantindo que pacientes com tumores malignos recebam atenção prioritária.

1.3 Possíveis Aplicações

As aplicações práticas resultantes do desenvolvimento desta técnica de classificação incluem:

- **Sistemas de Apoio à Decisão Clínica (SADC):** softwares que atuam como uma segunda opinião para patologistas em hospitais e laboratórios.
- **Triagem Automatizada:** ferramentas para organizar filas de exames, priorizando casos onde a probabilidade de malignidade detectada pela IA é mais alta.
- **Análise Multivariada em Pesquisa Oncológica:** descoberta de correlações estatísticas entre parâmetros físicos das células e a progressão da doença.
- **Plataformas de Telemedicina:** auxílio diagnóstico em regiões com escassez de médicos especialistas, permitindo uma análise preliminar baseada em dados computacionais.

1.4 Objetivo

Desenvolver um modelo de Machine Learning capaz de classificar tumores de mama em benignos ou malignos com base em características extraídas de exames, buscando alta acurácia e suporte ao diagnóstico médico. Nesta etapa acadêmica, os modelos são avaliados como classificadores sobre uma base de dados, e não como ferramentas clínicas.

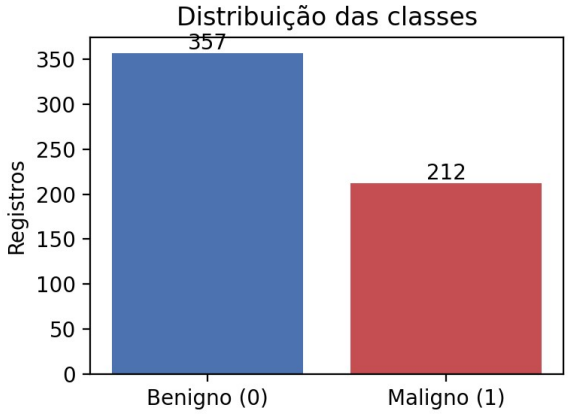
1.5 Base de dados e pré-processamento

O conjunto de dados utilizado é o Breast Cancer Wisconsin (Diagnostic), criado por Wolberg, Street e Mangasarian (1995) e disponibilizado pelo UCI Machine Learning Repository, tendo sido obtido para este trabalho por meio do Kaggle (UCI MACHINE LEARNING, [s.d.]). Ele contém 569 registros e 30 atributos numéricos preditivos (média, erro padrão e pior valor de dez medidas do núcleo celular, como raio, textura, perímetro, área e concavidade), além da variável de diagnóstico. Há 357 casos benignos (62,7%) e 212 malignos (37,3%), conforme a Figura 1. O pré-processamento consistiu em:

- **Valores ausentes:** não foram encontrados valores nulos nas variáveis preditoras, portanto nenhuma remoção de registros foi necessária.
- **Remoção de colunas irrelevantes:** a coluna de identificação (*id*) foi descartada por não contribuir para o modelo, assim como a coluna *Unnamed: 32*, que veio sem dados no CSV.
- **Conversão de dados:** a variável *diagnosis* foi convertida para valores numéricos: M = 1 (maligno) e B = 0 (benigno). Os demais atributos já são numéricos.
- **Variáveis temporais:** a base não possui atributos de data ou hora, portanto essa análise não se aplica.
- **Padronização:** aplicada por StandardScaler aos algoritmos sensíveis à escala das variáveis (SVM, MLP e k-NN), sempre dentro de um Pipeline, de modo que o scaler seja ajustado somente com os dados de treinamento de cada divisão, evitando vazamento de informação (*data leakage*). O Gradient Boosting, baseado em árvores de decisão, não exige padronização.

Após o tratamento, permaneceram 30 variáveis preditoras e 1 variável alvo.

Figura 1 — Distribuição das classes na base completa



Fonte: elaborado pelos autores (2026).

2. Materiais e Métodos — atualização

2.1 Divisão dos dados e estratégia de validação

Foi adotada a divisão *hold-out* de 80% para treinamento e 20% para teste, o que corresponde a 455 e 114 registros, respectivamente. A proporção foi escolhida porque a base é pequena: 80% mantém dados suficientes para o aprendizado dos modelos (30 variáveis), enquanto 20% fornece um conjunto de teste com tamanho razoável para estimar o desempenho em dados não vistos. A divisão foi **estratificada**, preservando a proporção de benignos e

malignos nos dois conjuntos, e *random_state*=42 foi usado para reprodutibilidade. A Tabela 1 apresenta a distribuição das classes em cada conjunto.

Tabela 1 — Distribuição das classes nos conjuntos de treinamento e teste

Conjunto	Total	Benignos	Malignos
Treinamento (80%)	455	285 (62,6%)	170 (37,4%)
Teste (20%)	114	72 (63,2%)	42 (36,8%)
Base completa	**569**	**357 (62,7%)**	**212 (37,3%)**

Fonte: elaborado pelos autores (2026).

Desbalanceamento das classes. A base é moderadamente desbalanceada: a classe benigna representa 62,7% dos registros e a maligna 37,3% (proporção de cerca de 1,7:1). Isso exige cuidado na avaliação, pois um classificador que sempre prevesse "benigno" já teria 62,7% de acurácia, de modo que essa métrica isolada pode ser enganosa. Por isso foram adotadas quatro medidas: (i) divisão treino/teste estratificada, mantendo a proporção das classes nos dois conjuntos (Tabela 1); (ii) validação cruzada estratificada, que preserva a proporção em cada *fold*; (iii) uso de Precisão, Recall e F1-Score, além da acurácia, com atenção especial ao recall da classe maligna; e (iv) reamostragem da classe minoritária pela técnica SMOTE, descrita na Seção 2.3 e avaliada na Seção 4.

Como o conjunto de teste tem apenas 42 casos malignos, cada caso errado altera o recall em cerca de 2,4 pontos percentuais, e o resultado de uma única divisão pode ser instável. Por isso, além do *hold-out*, utilizou-se a **validação cruzada aninhada**: no laço externo, os dados são divididos em 5 partes (5-fold estratificado, repetido 2 vezes, totalizando 10 avaliações) e cada parte serve como teste enquanto as outras treinam o modelo; no laço interno, em cada treinamento, os hiperparâmetros são escolhidos por busca em grade com validação cruzada de 3 partes. Dessa forma, o desempenho estimado inclui o processo de ajuste dos hiperparâmetros e os dados de teste nunca participam dessa escolha. Reporta-se a média e o desvio padrão das métricas.

2.2 Algoritmos selecionados

Foram selecionados quatro algoritmos de classificação de naturezas diferentes, o que torna a comparação mais informativa: um método de margem máxima, uma rede neural, um método baseado em instâncias e um ensemble de árvores com reforço.

Máquina de Vetores de Suporte (SVM) com kernel RBF: busca a fronteira de decisão que maximiza a margem entre as duas classes (CORTES; VAPNIK, 1995). O kernel RBF permite fronteiras não lineares ao mapear implicitamente os dados para um espaço de maior dimensão. O hiperparâmetro C controla a penalização dos erros de classificação e gamma define o alcance da influência de cada exemplo.

Rede Neural Multi-Layer Perceptron (MLP): rede neural direta (feedforward) com uma ou mais camadas ocultas de ativação ReLU, saída logística e treinamento pelo otimizador Adam. Aprende combinações não lineares das 30 variáveis. Foi usada regularização L2 (parâmetro alpha), no máximo 2000 iterações e random_state=42.

k-Vizinhos Mais Próximos (k-NN): método baseado em instâncias, sem fase de treinamento propriamente dita: um novo caso é classificado pelo voto dos k exemplos de treinamento mais próximos, segundo a distância euclidiana no espaço de variáveis padronizadas (COVER; HART, 1967). Os hiperparâmetros são o número de vizinhos e o esquema de pesos dos votos.

Gradient Boosting: ensemble construído de forma sequencial, em que cada árvore de decisão rasa corrige os erros acumulados pelas anteriores, seguindo o gradiente da função de perda (FRIEDMAN, 2001). Os hiperparâmetros ajustados foram o número de árvores, a taxa de aprendizado e a profundidade máxima.

Os hiperparâmetros de cada algoritmo foram escolhidos por busca em grade (GridSearchCV), usando o F1-Score como critério e somente os dados de treinamento. A Tabela 2 apresenta os valores testados.

Tabela 2 — Grade de hiperparâmetros testada para cada algoritmo

Algoritmo	Hiperparâmetros testados
SVM (RBF)	C ∈ {0,1; 1; 10}; gamma ∈ {scale; 0,01}
MLP	camadas ocultas ∈ {(16); (32, 16)}; alpha ∈ {0,0001; 0,01}
k-NN	k ∈ {3; 5; 9; 15}; pesos ∈ {uniforme; distância}
Gradient Boosting	n_estimators ∈ {100; 200}; learning_rate ∈ {0,05; 0,1}; max_depth ∈ {2; 3}

Fonte: elaborado pelos autores (2026).

2.3 Tratamento do desbalanceamento (SMOTE)

Cada algoritmo foi treinado em duas versões, com a mesma divisão, a mesma semente e os mesmos folds: sem tratamento do desbalanceamento e com SMOTE (*Synthetic Minority Over-sampling Technique*; CHAWLA et al., 2002). O SMOTE cria exemplos sintéticos da classe minoritária (maligna) por interpolação entre um caso real e seus vizinhos mais próximos, equalizando as classes no treinamento (no *hold-out*, de 285 benignos e 170 malignos para 285 de cada). A técnica foi implementada com a biblioteca imbalanced-learn (LEMAÎTRE; NOGUEIRA; ARIDAS, 2017), dentro do Pipeline, de modo que é aplicada **apenas nos dados de treinamento** de cada divisão ou fold; os dados de teste e de validação mantêm a distribuição original e nenhum exemplo sintético vaza para a avaliação.

2.4 Métricas de avaliação e critério de escolha do melhor modelo

A classe positiva é a classe 1 (tumor maligno). Foram utilizadas: Acurácia (proporção de acertos totais); Precisão (dos tumores previstos como malignos, quantos realmente o eram); Recall (dos tumores malignos reais, quantos foram identificados) e F1-Score (média harmônica entre precisão e recall), além da Matriz de Confusão. Em um problema de diagnóstico, o falso negativo (tumor maligno classificado como benigno) é o erro mais grave. Por isso, o critério de escolha do melhor modelo foi definido antes da execução dos experimentos: maior recall médio na validação cruzada aninhada, com o F1-Score como critério de desempate.

2.5 Ferramentas

Python foi utilizado na implementação. As principais bibliotecas foram Pandas e NumPy (manipulação de dados), Scikit-Learn (modelos, divisão, busca em grade, validação cruzada, métricas e importância por permutação), imbalanced-learn (SMOTE e Pipeline com reamostragem) e Matplotlib (gráficos). O código-fonte completo (treinamento_classificacao_v3.py) acompanha este relatório e está disponível no repositório GitHub do projeto: https://github.com/chernns/Projeto-IA

3. Resultados e Discussão — parcial

3.1 Hiperparâmetros selecionados

A Tabela 3 mostra os hiperparâmetros escolhidos pela busca em grade no conjunto de treinamento do hold-out, para cada algoritmo e versão.

Tabela 3 — Hiperparâmetros selecionados na busca em grade (conjunto de treinamento)

Algoritmo	Sem tratamento	Com SMOTE
SVM (RBF)	C=10; gamma=scale	C=10; gamma=0,01
MLP	camada (16); alpha=0,0001	camada (16); alpha=0,0001
k-NN	k=3; pesos uniformes	k=15; pesos uniformes
Gradient Boosting	200 árvores; taxa 0,1; prof. 2	200 árvores; taxa 0,1; prof. 2

Fonte: elaborado pelos autores (2026).

3.2 Desempenho no conjunto de teste (hold-out 80/20)

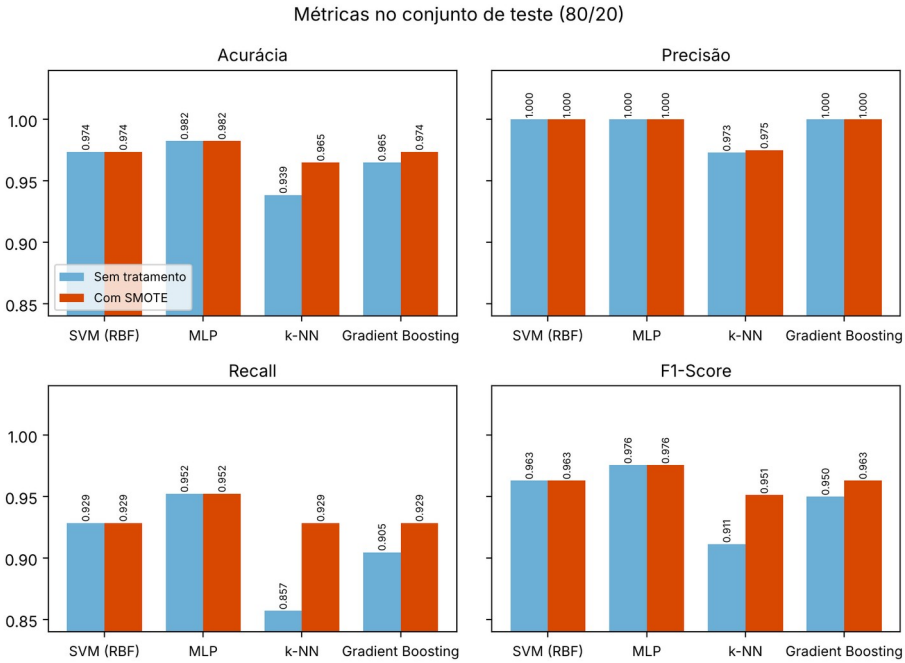
A avaliação foi realizada sobre o conjunto de teste, que não participou do treinamento nem da escolha dos hiperparâmetros. A Tabela 4 e a Figura 2 apresentam as métricas, e a Figura 3 as matrizes de confusão.

Tabela 4 — Métricas no conjunto de teste (hold-out 80/20)

Modelo	Acurácia	Precisão	Recall	F1-Score	Falsos neg.
SVM (RBF)	0.9737	1.0000	0.9286	0.9630	3
SVM (RBF) + SMOTE	0.9737	1.0000	0.9286	0.9630	3
MLP	0.9825	1.0000	0.9524	0.9756	2
MLP + SMOTE	0.9825	1.0000	0.9524	0.9756	2
k-NN	0.9386	0.9730	0.8571	0.9114	6
k-NN + SMOTE	0.9649	0.9750	0.9286	0.9512	3
Gradient Boosting	0.9649	1.0000	0.9048	0.9500	4
Gradient Boosting + SMOTE	0.9737	1.0000	0.9286	0.9630	3

Fonte: elaborado pelos autores (2026).

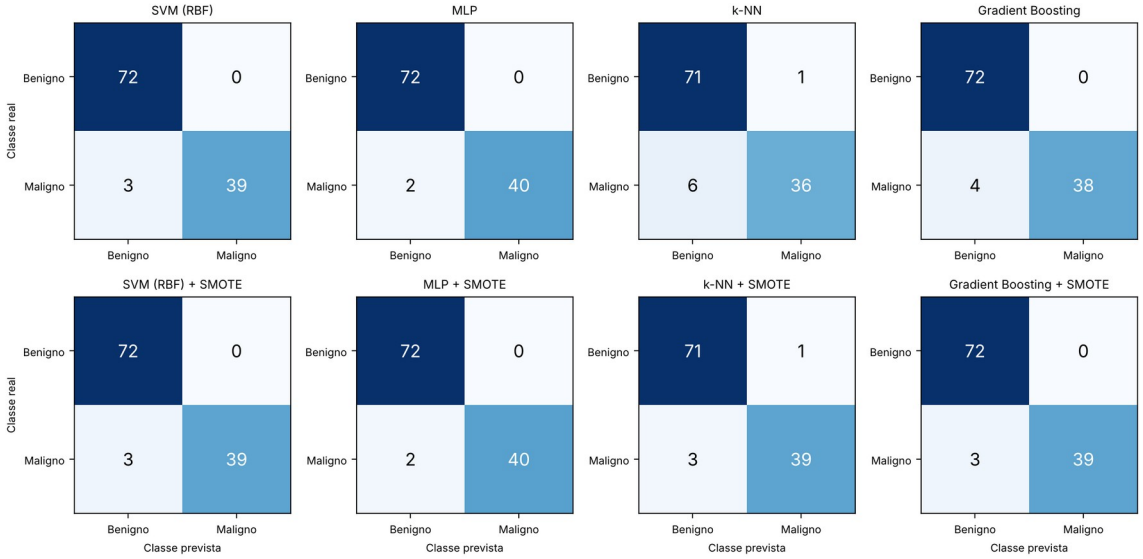
Figura 2 — Métricas dos modelos no conjunto de teste: sem tratamento e com SMOTE



Fonte: elaborado pelos autores (2026).

3.3 Matrizes de confusão

Figura 3 — Matrizes de confusão no conjunto de teste (114 registros)



Fonte: elaborado pelos autores (2026).

3.4 Validação cruzada aninhada (5-fold × 2)

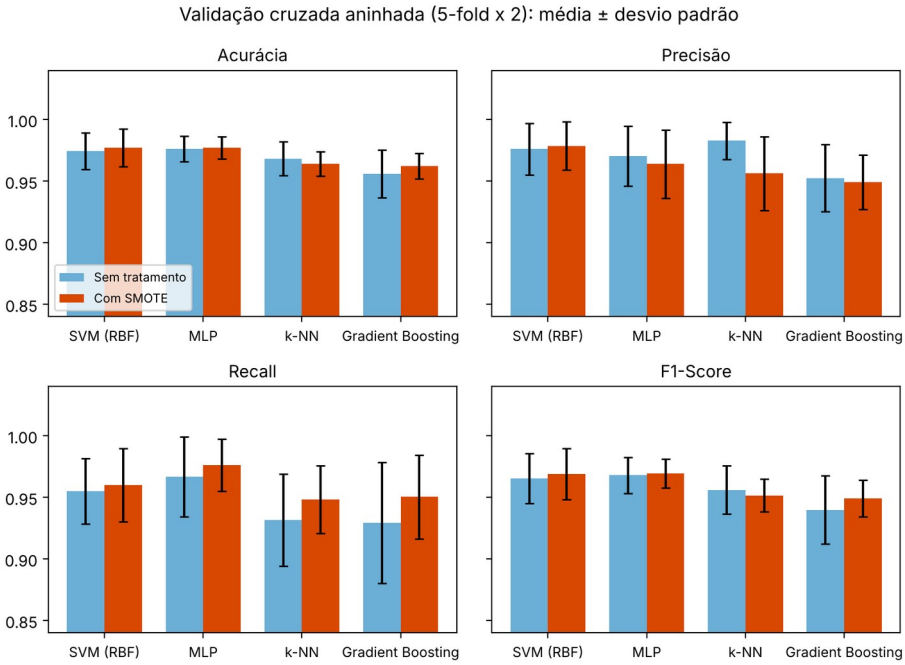
Para verificar se o resultado da divisão única se mantém, as métricas foram recalculadas por validação cruzada aninhada, em que a busca de hiperparâmetros é refeita dentro de cada treinamento (média ± desvio padrão das 10 avaliações), conforme a Tabela 5 e a Figura 4.

Tabela 5 — Validação cruzada aninhada (5-fold × 2): média ± desvio padrão

Modelo	Acurácia	Precisão	Recall	F1-Score
SVM (RBF)	0.9745 ± 0.0150	0.9761 ± 0.0211	0.9552 ± 0.0266	0.9654 ± 0.0202
SVM (RBF) + SMOTE	0.9772 ± 0.0153	0.9787 ± 0.0195	0.9600 ± 0.0299	0.9690 ± 0.0209
MLP	0.9763 ± 0.0105	0.9703 ± 0.0244	0.9668 ± 0.0322	0.9679 ± 0.0146
MLP + SMOTE	0.9772 ± 0.0090	0.9640 ± 0.0276	0.9763 ± 0.0212	0.9696 ± 0.0117
k-NN	0.9684 ± 0.0137	0.9829 ± 0.0152	0.9316 ± 0.0373	0.9560 ± 0.0197
k-NN + SMOTE	0.9640 ± 0.0099	0.9563 ± 0.0301	0.9482 ± 0.0274	0.9515 ± 0.0133
Gradient Boosting	0.9561 ± 0.0192	0.9526 ± 0.0273	0.9293 ± 0.0490	0.9399 ± 0.0276
Gradient Boosting + SMOTE	0.9622 ± 0.0104	0.9492 ± 0.0220	0.9504 ± 0.0340	0.9491 ± 0.0147

Fonte: elaborado pelos autores (2026).

Figura 4 — Métricas na validação cruzada aninhada (barras de erro = desvio padrão)



Fonte: elaborado pelos autores (2026).

4. Discussão comparativa e escolha do melhor modelo

Hold-out 80/20. A MLP foi o modelo de melhor desempenho no conjunto de teste, com acurácia de 98,25%, precisão de 100%, recall de 95,24% e F1-Score de 97,56%, errando apenas 2 dos 42 casos malignos e nenhum benigno. A SVM obteve acurácia de 97,37% e 3 falsos negativos. O Gradient Boosting teve 4 falsos negativos (recall de 90,48%) e o k-NN teve o pior resultado, com 6 falsos negativos e recall de 85,71%. Vale lembrar que, no teste, cada caso equivale a 2,4 pontos percentuais de recall.

Validação cruzada aninhada. A mesma ordem geral se manteve em uma avaliação mais estável. Na média das 10 avaliações, a MLP com SMOTE obteve o maior recall (97,63%) e o maior F1-Score (96,96%), além de acurácia de 97,72% (empatada com a SVM com SMOTE). Em seguida vieram a MLP sem SMOTE (recall de 96,68%) e a SVM com SMOTE (96,00%). O

Gradient Boosting e o k-NN ficaram abaixo, com recall entre 92,9% e 95,0%. A Tabela 6 resume o ranking segundo o critério definido na Seção 2.4.

Tabela 6 — Ranking dos modelos pelo critério definido (recall médio; desempate pelo F1-Score)

Posição	Modelo	Recall médio	F1-Score médio
1º	MLP + SMOTE	0.9763	0.9696
2º	MLP	0.9668	0.9679
3º	SVM (RBF) + SMOTE	0.9600	0.9690
4º	SVM (RBF)	0.9552	0.9654
5º	Gradient Boosting + SMOTE	0.9504	0.9491
6º	k-NN + SMOTE	0.9482	0.9515
7º	k-NN	0.9316	0.9560
8º	Gradient Boosting	0.9293	0.9399

Fonte: elaborado pelos autores (2026).

Efeito do SMOTE. O SMOTE aumentou o recall médio dos quatro algoritmos na validação aninhada: de 95,52% para 96,00% na SVM, de 96,68% para 97,63% na MLP, de 93,16% para 94,82% no k-NN e de 92,93% para 95,04% no Gradient Boosting. O ganho foi maior nos algoritmos que partiram de recall mais baixo. No teste, o SMOTE reduziu os falsos negativos do k-NN (de 6 para 3) e do Gradient Boosting (de 4 para 3), sem efeito na SVM e na MLP. Em contrapartida, a precisão caiu na MLP (de 97,03% para 96,40%) e principalmente no k-NN (de 98,29% para 95,63%), ou seja, o modelo passa a aceitar mais falsos positivos. O F1-Score variou pouco (entre −0,5 e +0,9 ponto), de modo que o SMOTE reequilibrou os tipos de erro sem alterar muito o desempenho global.

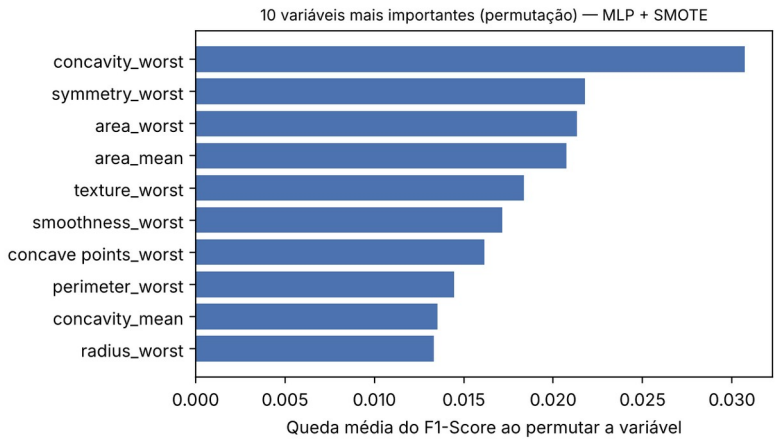
Modelo escolhido. Segundo o critério definido previamente (maior recall médio na validação cruzada aninhada, com desempate pelo F1-Score), o melhor modelo para este problema é a **Rede Neural MLP com SMOTE**. Ela obteve o maior recall (97,63%), o maior F1-Score (96,96%), acurácia equivalente à melhor (97,72%) e o menor desvio padrão do recall entre todos os modelos (2,12 pontos), além de, no hold-out, ter errado apenas 2 dos 42 tumores malignos e nenhum benigno. A SVM com SMOTE apresentou precisão mais alta que a da MLP (97,87% contra 96,40%) e é a alternativa mais simples e rápida de treinar.

Ressalvas. A diferença entre a MLP com SMOTE e os modelos seguintes (cerca de 1 a 2 pontos de recall) é menor que o desvio padrão entre as avaliações (de 2 a 3 pontos), e a base tem apenas 212 casos malignos; portanto, a escolha é a mais bem sustentada pelos resultados, mas não representa uma superioridade estatisticamente comprovada. Já a inferioridade do k-NN e do Gradient Boosting sem tratamento é mais clara, com recall médio abaixo de 94%. A MLP com SMOTE também tem a menor precisão entre os quatro melhores (96,40%), o que significa mais falsos positivos, um erro menos grave que o falso negativo em triagem, mas que gera exames adicionais.

Variáveis mais relevantes. Para a MLP com SMOTE, foi calculada a importância por permutação no conjunto de teste, isto é, a queda do F1-Score quando os valores de uma variável são embaralhados (Figura 5). As variáveis de maior impacto foram *concavity_worst*, *symmetry_worst*, *area_worst* e *area_mean*, seguidas por textura e suavidade, o que é coerente com o conhecimento do domínio, pois indica que forma, tamanho e irregularidade do núcleo celular são informativos para o diagnóstico. Como muitas variáveis são fortemente

correlacionadas, a informação de uma é parcialmente compensada pelas outras quando embaralhada, e por isso as quedas individuais são pequenas.

Figura 5 — Importância das variáveis por permutação (MLP com SMOTE, conjunto de teste)



Fonte: elaborado pelos autores (2026).

Observação: os resultados são experimentais e acadêmicos. Não representam validação clínica nem autorizam o uso dos modelos para diagnóstico de pacientes.

5. Conclusão parcial

A terceira entrega permitiu implementar e comparar quatro algoritmos de classificação de naturezas distintas (SVM, MLP, k-NN e Gradient Boosting) sobre a base Breast Cancer Wisconsin (Diagnostic), com divisão estratificada de 80% para treinamento e 20% para teste, ajuste de hiperparâmetros por busca em grade e validação cruzada aninhada. O desbalanceamento moderado das classes (62,7% x 37,3%) foi tratado com SMOTE aplicado apenas aos dados de treinamento, o que elevou o recall da classe maligna nos quatro algoritmos, em troca de menor precisão em parte deles. Todos os modelos tiveram acurácia acima de 95% na validação aninhada, e o melhor comportamento, segundo o critério de maior recall médio, foi o da Rede Neural MLP com SMOTE (recall de 97,63%, F1-Score de 96,96% e acurácia de 97,72%), com ressalva de que a diferença para a SVM e para a MLP sem SMOTE é pequena diante da variação entre as avaliações. Como continuidade, recomenda-se a validação em uma base externa, o ajuste do limiar de decisão para reduzir ainda mais os falsos negativos, o uso de mais repetições na validação cruzada e a combinação de modelos (ensemble) entre MLP e SVM.

6. Referências Bibliográficas

CHAWLA, N. V.; BOWYER, K. W.; HALL, L. O.; KEGELMEYER, W. P. SMOTE: Synthetic Minority Over-sampling Technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273–297, 1995.

COVER, T.; HART, P. Nearest neighbor pattern classification. **IEEE Transactions on Information Theory**, v. 13, n. 1, p. 21–27, 1967.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001.

LEMAÎTRE, G.; NOGUEIRA, F.; ARIDAS, C. K. Imbalanced-learn: a Python toolbox to tackle the curse of imbalanced datasets in machine learning. **Journal of Machine Learning Research**, v. 18, n. 17, p. 1–5, 2017.

SILVA FILHO, A. R.; GOMES, A. H. S. **Projeto IA — Diagnóstico de Câncer de Mama** (código-fonte, base e figuras). GitHub. Disponível em: https://github.com/chernns/Projeto-IA.

WOLBERG, W. H.; STREET, W. N.; MANGASARIAN, O. L. **Breast Cancer Wisconsin (Diagnostic)**. UCI Machine Learning Repository, 1995. DOI: 10.24432/C5DW2B.

UCI MACHINE LEARNING. **Breast Cancer Wisconsin (Diagnostic) Data Set**. Kaggle, [s.d.]. Disponível em: https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data. Acesso em: 17 set. 2026.

IMBALANCED-LEARN. **SMOTE**. Disponível em: https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTE.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **SVC documentation**. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **MLPClassifier documentation**. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **KNeighborsClassifier documentation**. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **GradientBoostingClassifier documentation**. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingClassifier.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **GridSearchCV documentation**. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **Nested versus non-nested cross-validation**. Disponível em: https://scikit-learn.org/stable/auto_examples/model_selection/plot_nested_cross_validation_iris.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **Permutation feature importance**. Disponível em: https://scikit-learn.org/stable/modules/permutation_importance.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **Confusion matrix documentation**. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **Metrics documentation**. Disponível em: https://scikit-learn.org/stable/api/sklearn.metrics.html. Acesso em: 9 nov. 2026.

SCIKIT-LEARN. **Cross-validation: evaluating estimator performance**. Disponível em: https://scikit-learn.org/stable/modules/cross_validation.html. Acesso em: 9 nov. 2026.