Projeto de Inteligência Artificial

Diagnóstico de Câncer de Mama — 3ª Entrega Parcial

Dupla: Ailton Rodrigo da Silva Filho

Arthur Henrique da Silva Gomes

Professora: Patricia Bellin Ribeiro

Tema: Classificação de Tumores de Mama em Benignos ou Malignos utilizando Machine Learning.

1. Estrutura anterior consolidada

1.1 Introdução e Contextualização

O câncer de mama é uma das doenças de maior impacto na saúde global, sendo a principal causa de morte por câncer entre as mulheres em diversos países. A complexidade desta patologia exige métodos de diagnóstico que sejam não apenas rápidos, mas extremamente precisos, uma vez que a detecção precoce eleva drasticamente as chances de cura e permite tratamentos menos invasivos.

Este projeto fundamenta-se na utilização do conjunto de dados 'Breast Cancer Wisconsin (Diagnostic)', um recurso amplamente reconhecido na comunidade científica e de Machine Learning. O dataset contém informações extraídas de imagens digitalizadas de biópsias realizadas por aspiração por agulha fina (PAAF). Os dados quantificam características dos núcleos celulares, como o raio médio, a textura, a suavidade e a concavidade, permitindo que algoritmos de Inteligência Artificial aprendam a distinguir padrões associados a tumores benignos e malignos.

1.2 Relevância

A relevância deste projeto está ancorada na interseção entre tecnologia e medicina. O diagnóstico patológico tradicional, embora altamente confiável, está sujeito a variações interpretativas e à alta carga de trabalho dos profissionais. A implementação de modelos de IA como ferramenta auxiliar oferece:

- **Consistência Diagnóstica:** redução da subjetividade na análise morfológica celular.
- **Eficiência Operacional:** processamento rápido de dados para suporte imediato ao médico.
- **Redução de Erros:** auxílio na minimização de falso-negativos, garantindo que pacientes com tumores malignos recebam atenção prioritária.

1.3 Possíveis Aplicações

As aplicações práticas resultantes do desenvolvimento desta técnica de classificação incluem:

- **Sistemas de Apoio à Decisão Clínica (SADC):** softwares que atuam como uma segunda opinião para patologistas em hospitais e laboratórios.
- **Triagem Automatizada:** ferramentas para organizar filas de exames, priorizando casos onde a probabilidade de malignidade detectada pela IA é mais alta.
- **Análise Multivariada em Pesquisa Oncológica:** descoberta de correlações estatísticas entre parâmetros físicos das células e a progressão da doença.
- **Plataformas de Telemedicina:** auxílio diagnóstico em regiões com escassez de médicos especialistas, permitindo uma análise preliminar baseada em dados computacionais.

1.4 Objetivo

Desenvolver um modelo de Machine Learning capaz de classificar tumores de mama em benignos ou malignos com base em características extraídas de exames, buscando alta acurácia e suporte ao diagnóstico médico. Nesta etapa acadêmica, os modelos são avaliados como classificadores sobre uma base de dados, e não como ferramentas clínicas.

1.5 Base de dados e pré-processamento

O conjunto de dados utilizado é o Breast Cancer Wisconsin (Diagnostic), obtido do Kaggle. Ele contém 569 registros e 30 atributos numéricos preditivos (média, erro padrão e pior valor de dez medidas do núcleo celular, como raio, textura, perímetro, área e concavidade), além da variável de diagnóstico. Há 357 casos benignos (62,7%) e 212 malignos (37,3%). O pré-processamento consistiu em:

- **Valores ausentes:** não foram encontrados valores nulos nas variáveis preditoras, portanto nenhuma remoção de registros foi necessária.
- **Remoção de colunas irrelevantes:** a coluna de identificação (*id*) foi descartada por não contribuir para o modelo, assim como a coluna *Unnamed: 32*, que veio sem dados no CSV.
- **Conversão de dados:** a variável *diagnosis* foi convertida para valores numéricos: M = 1 (maligno) e B = 0 (benigno). Os demais atributos já são numéricos.
- **Variáveis temporais:** a base não possui atributos de data ou hora, portanto essa análise não se aplica.
- **Padronização:** prevista na etapa anterior para etapas futuras, foi aplicada nesta entrega por StandardScaler para a Regressão Logística, dentro de um Pipeline, de modo que o scaler seja ajustado somente com os dados de treinamento, evitando vazamento de informação (*data leakage*). O Random Forest não exige padronização, pois é baseado em divisões por limiares.

Após o tratamento, permaneceram 30 variáveis preditoras e 1 variável alvo.

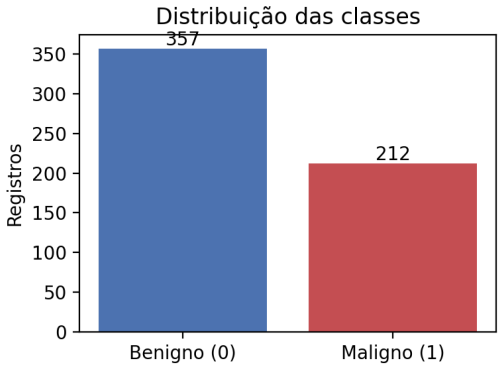


Figura 1 — Distribuição das classes na base completa.

2. Materiais e Métodos — atualização

2.1 Divisão dos dados e estratégia de validação

Foi adotada a divisão *hold-out* de 80% para treinamento e 20% para teste, o que corresponde a 455 e 114 registros, respectivamente. A proporção foi escolhida porque a base é pequena: 80% mantém dados suficientes para o aprendizado dos modelos (30 variáveis), enquanto 20% fornece um conjunto de teste com tamanho razoável para estimar o desempenho em dados não vistos. A divisão foi **estratificada**, preservando a proporção de benignos e malignos nos dois conjuntos, e *random_state*=42 foi usado para reprodutibilidade.

Conjunto	Total	Benignos	Malignos
Treinamento (80%)	455	285	170
Teste (20%)	114	72	42

Como o conjunto de teste tem apenas 42 casos malignos, cada caso errado altera o recall em cerca de 2,4 pontos percentuais, e o resultado de uma única divisão pode ser instável. Por isso, como complemento, também foi aplicada **validação cruzada estratificada com 5 folds** sobre toda a base: os dados são divididos em 5 partes, e cada parte serve uma vez como teste enquanto as outras 4 treinam o modelo. Reporta-se a média e o desvio padrão das métricas.

2.2 Algoritmos selecionados

Regressão Logística: classificador linear supervisionado para classificação binária. Combina linearmente as variáveis e aplica a função sigmoide para estimar a probabilidade de o tumor ser maligno; a classe é definida pelo limiar de 0,5. Foi utilizada regularização L2 padrão (C=1), *max_iter*=5000 e variáveis padronizadas. É um modelo simples, rápido e interpretável.

Random Forest: conjunto (*ensemble*) de árvores de decisão treinadas em amostras *bootstrap* dos dados e com sorteio aleatório de variáveis a cada divisão; a classe final é decidida por votação. Captura relações não lineares e interações entre variáveis, sendo de natureza diferente da Regressão Logística, o que torna a comparação mais informativa. Foram utilizadas 300 árvores e *random_state*=42.

2.3 Métricas de avaliação

A classe positiva é a classe 1 (tumor maligno). Foram utilizadas: **Acurácia** (proporção de acertos totais); **Precisão** (dos tumores previstos como malignos, quantos realmente o eram); **Recall** (dos tumores malignos reais, quantos foram identificados) e **F1-Score** (média harmônica entre precisão e recall), além da **Matriz de Confusão**. Em um problema de diagnóstico, o recall merece atenção especial, pois um falso negativo representa um tumor maligno classificado como benigno.

2.4 Ferramentas

Python foi utilizado na implementação. As principais bibliotecas foram Pandas e NumPy (manipulação de dados), Scikit-Learn (modelos, divisão, validação cruzada e métricas) e Matplotlib (gráficos). O código-fonte completo (*treinamento_classificacao.py*) acompanha este relatório e está disponível no repositório GitHub do projeto: https://github.com/chernns/Projeto-IA

3. Resultados e Discussão — parcial

3.1 Desempenho no conjunto de teste (hold-out 80/20)

A avaliação foi realizada sobre o conjunto de teste, que não participou do treinamento.

Modelo	Acurácia	Precisão	Recall	F1-Score
Regressão Logística	0.9649	0.9750	0.9286	0.9512
Random Forest	0.9737	1.0000	0.9286	0.9630

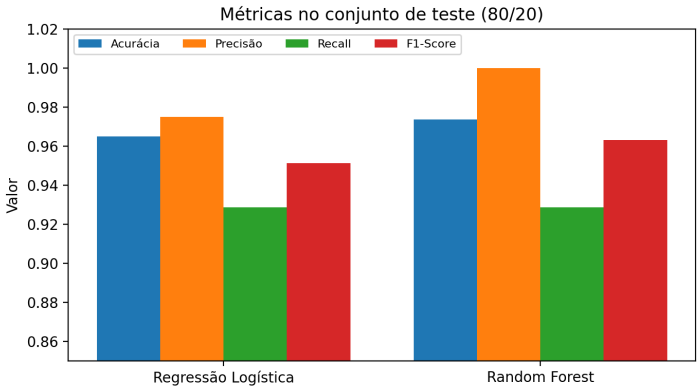


Figura 2 — Métricas dos modelos no conjunto de teste.

3.2 Matrizes de confusão

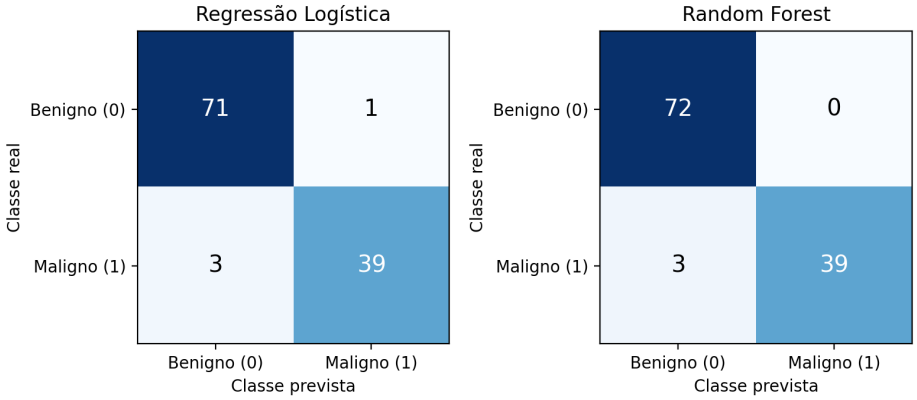


Figura 3 — Matrizes de confusão no conjunto de teste (114 registros).

3.3 Validação cruzada estratificada (5-fold)

Para verificar se o resultado da divisão única se mantém, as métricas foram recalculadas por validação cruzada (média ± desvio padrão dos 5 folds).

Modelo	Acurácia	Precisão	Recall	F1-Score
Regressão Logística	0.9737 ± 0.0166	0.9863 ± 0.0182	0.9436 ± 0.0525	0.9633 ± 0.0240
Random Forest	0.9526 ± 0.0131	0.9461 ± 0.0389	0.9295 ± 0.0572	0.9355 ± 0.0194

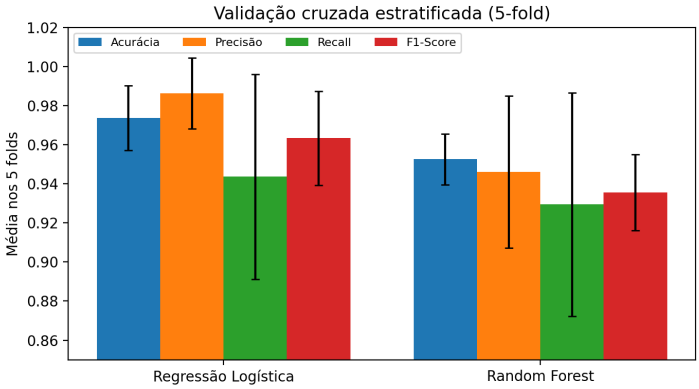


Figura 4 — Média das métricas na validação cruzada (barras de erro = desvio padrão).

4. Discussão comparativa inicial

Hold-out 80/20. A Regressão Logística obteve acurácia de 96,49%, precisão de 97,50%, recall de 92,86% e F1-Score de 95,12%, com 71 benignos corretos, 1 falso positivo, 3 falsos negativos e 39 malignos corretos. O Random Forest obteve acurácia de 97,37%, precisão de 100,00%, recall de 92,86% e F1-Score de 96,30%, com 72 benignos corretos, nenhum falso positivo, 3 falsos negativos e 39 malignos corretos. Nessa divisão, o Random Forest foi superior em acurácia, precisão e F1-Score, e os dois modelos empataram no recall: ambos deixaram de identificar 3 dos 42 casos malignos.

Validação cruzada. Na média dos 5 folds, a ordem se inverte: a Regressão Logística obteve acurácia de 97,37%, precisão de 98,63%, recall de 94,36% e F1-Score de 96,33%, contra 95,26%, 94,61%, 92,95% e 93,55% do Random Forest. Ou seja, a vantagem do Random Forest no hold-out parece estar ligada àquela divisão específica dos dados, e não a uma superioridade geral.

Interpretação. O desvio padrão do recall na validação cruzada é alto (cerca de 5 pontos percentuais nos dois modelos), indicando que a diferença de recall entre eles é pequena diante da variação entre folds. Considerando as duas estratégias em conjunto, os modelos têm desempenho muito próximo, com leve vantagem da Regressão Logística na validação cruzada, que é uma estimativa mais estável por usar todos os dados. A boa performance de um modelo linear sugere que as classes são bem separáveis nesta base, o que também ajuda a explicar a alta acurácia de ambos. O Random Forest indica como variáveis mais relevantes medidas de tamanho e forma do núcleo, em especial *perimeter_worst*, *area_worst* e *concave points_worst*, o que é coerente com o conhecimento do domínio.

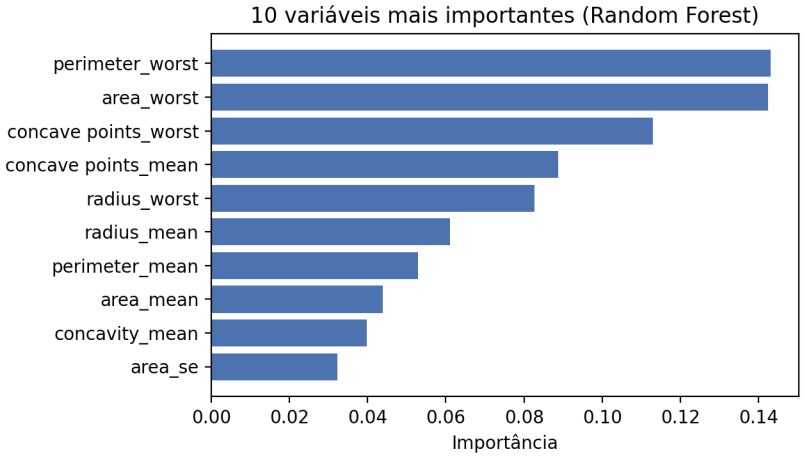


Figura 5 — Importância das variáveis segundo o Random Forest.

Observação: os resultados são experimentais e acadêmicos. Não representam validação clínica nem autorizam o uso dos modelos para diagnóstico de pacientes.

5. Conclusão parcial

A terceira entrega permitiu implementar e avaliar dois algoritmos de classificação sobre a base Breast Cancer Wisconsin (Diagnostic), utilizando divisão estratificada de 80% para treinamento e 20% para teste, complementada por validação cruzada de 5 folds, e métricas de classificação com matrizes de confusão. Os dois modelos tiveram desempenho elevado (acurácia acima de 95%) e próximo entre si, e a comparação entre hold-out e validação cruzada mostrou que a escolha do melhor modelo depende da estratégia de validação. Como continuidade, recomenda-se o ajuste de hiperparâmetros (por exemplo, C da Regressão Logística e profundidade das árvores), a priorização do recall como critério de seleção e a avaliação de um terceiro algoritmo, como Multi-Layer Perceptron.

6. Referências Bibliográficas

SILVA FILHO, A. R.; GOMES, A. H. S. Projeto IA — Diagnóstico de Câncer de Mama (código-fonte, base e figuras). GitHub. https://github.com/chernns/Projeto-IA.

KAGGLE. Breast Cancer Wisconsin (Diagnostic) Data Set. https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data. Acesso em: 17 set. 2026.

SCIKIT-LEARN. LogisticRegression documentation. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html. Acesso em: 17 set. 2026.

SCIKIT-LEARN. RandomForestClassifier documentation. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html. Acesso em: 17 set. 2026.

SCIKIT-LEARN. Confusion matrix documentation. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html. Acesso em: 17 set. 2026.

SCIKIT-LEARN. Metrics documentation. https://scikit-learn.org/stable/api/sklearn.metrics.html. Acesso em: 17 set. 2026.

SCIKIT-LEARN. Cross-validation: evaluating estimator performance. https://scikit-learn.org/stable/modules/cross_validation.html. Acesso em: 17 set. 2026.